

1. 中文青少年内容安全

10 个一级风险领域



社会价值



教育



心理健康



身体健康



家庭与学校



数字平台



隐私与
合成媒体




财产与
商业利用



线下安全



法律与
公共秩序



2. 基准构建与任务设计

两类互补评测任务



10 种多轮风险机制

- | | | | | |
|----------|----------|----------|----------|----------|
| M01 意图递进 | M02 跨轮指代 | M03 有害组合 | M04 用途反转 | M05 风险回授 |
| M06 请求收缩 | M07 条件更新 | M08 规则累积 | M09 立场迁移 | M10 边界迁移 |

中文青少年情境示例



教育决策



家校沟通



平台规则




数字消费

3. 回答评测

兼顾安全性与帮助性的五档评分



识别风险



维护安全边界




提供适龄帮助

单轮风险领域结果



多轮风险机制结果



13 个开源模型



自动裁判



风险情境与用户请求



模型结合可用上下文作答



自动裁判按任务细则评分

